

MalarIA:

Clasificación de Células sanguíneas con Deep Learning

Integrantes:

- Cristhian Reaño Ccoscco - 20201181
- José Zapata Castro - 20211845
- Isaac Huamani Sulca - 20215421
- Sebastian Saco Alvarado - 20221648
- Carlos Camilo Vásquez Morales - 20202583



Problemas en el diagnóstico

El **diagnóstico manual de malaria** por microscopía es manual y lento. Un especialista revisa Laminillas de sangre por célula y el resultado depende directamente de su experiencia y tiempo disponible.

Objetivo: clasificar automáticamente imágenes de células individuales como ***Parasited o Uninfected.***

Aplicación: apoyo al diagnóstico clínico mediante inteligencia artificial, priorizando la detección de casos infectados (alta sensibilidad)

Carga global de Malaria:

282 M


Casos estimados en 2023

610,000

Muertes estimadas en 2023 principalmente en niños menores de 5 años en África subsahariana

Fuente: OMS, Fact sheet Malaria (World Malaria Report 2024)

Dataset de Malaria



Imágenes de células NIH / KAGGLE

27,558 imágenes de células individuales de frotis sanguíneo (tinción Giemsa), perfectamente balanceadas entre las dos clases

Parasitized	13,779
Uninfected	13,779
Train (70%)	19,290
Val (15%)	4,132
Test (15%)	4,136

Preprocesamiento de Datos

División y preparación de imágenes

Redimensionamiento

Se redimensionan las imágenes a **128x128** píxeles, asegurando uniformidad en el tamaño de entrada para el modelo, lo que facilita el procesamiento y mejora la eficiencia del entrenamiento.

Augmentación

Se aplican técnicas de **augmentación** como flips y rotaciones de hasta 15 grados, enriqueciendo el conjunto de datos y ayudando al modelo a generalizar mejor ante variaciones en las imágenes.

Normalización

Se normalizan las imágenes utilizando estadísticas de **ImageNet**, lo que ayuda a estabilizar el proceso de entrenamiento y a acelerar la convergencia del modelo al reducir sesgos en los datos.

Arquitectura: Modelo EfficientNet B0

Transfer learning

Arquitectura del Modelo

EfficientNet B0 se basa en una **arquitectura eficiente** que optimiza la precisión con menos parámetros. Esto permite un excelente rendimiento en tareas de clasificación de imágenes.

Fase 1: Feature extraction 35 épocas

Fases de Entrenamiento

El modelo se entrena en dos fases: primero, con el backbone congelado durante 35 épocas, seguido de 15 épocas de fine tuning para mejorar la precisión.

Fase 2: Fine-Tuning 15 épocas

Esta estrategia evita sobreajustar el backbone con un dataset de tamaño medio y luego lo especializa progresivamente en la textura de las células teñidas.

Hiperparámetros

Configuración del entrenamiento

- Batch size de 256 (ajustado dinámicamente según la memoria GPU disponible).
- 50 épocas totales: 35 feature extraction + 15 fine-tuning.
- Resolución de entrada de 128 x 128 px
- Optimizador AdamW, weight decay = $1e-4$
- Presición mixta (AMP) con GradScaler para acelerar el entrenamiento

ENTORNO DE EJECUCIÓN

GPU

Tesla T4 (14.56 GB)

Framework

PyTorch 2.11 + CUDA

Tiempo de entrenamiento

35.71 min

Tiempo total (con setup)

36.85 min

Justificación Técnica

Decisiones clave en el proyecto

Precisión y Parámetros

EfficientNet B0 ofrece **buena precisión** con un número reducido de parámetros, lo que lo hace ideal para entornos con recursos limitados como Google Colab.

Tamaño de Imagen

La elección de 128x128 permite procesar imágenes en batches grandes sin desbordar la memoria de la GPU, optimizando el rendimiento durante el entrenamiento.

Transfer Learning

Utilizar transfer learning es ventajoso ya que el dataset es de tamaño medio, lo que permite reutilizar features visuales de modelos preentrenados como ImageNet.

Resultados

Accuracy in test

96.76%

Precisión

97.22%

Parasitized

Recall
(sensibilidad)

96.28%

F1-score

96.74%

Uninfected

Matriz de confusión

Correcto

1991

Error

77

Error

57



Correcto

2011

Fila = clase real · Columna = predicción del modelo

El Recall se resalta porque, clínicamente, un falso negativo (paciente infectado no detectado) es más costoso que un falso positivo.

Curvas de entrenamiento




Al iniciar el fine-tuning (época 36) la accuracy de validación salta de 94.94% a 96.61% al final, evidenciando que al descongelar los bloques sí aporta una mejora real, no solo ruido.

Interpretabilidad con Grad-CAM

Grad-CAM genera un mapa de calor sobre la capa convolucional final, mostrando qué región de la célula más influyó en la predicción del modelo.

Este ejemplo real (primera imagen del set de test) resultó ser un caso límite: la célula es realmente Parasitized, pero el modelo predijo Uninfected con baja confianza (76.8%).

El mapa de calor lo confirma: en vez de concentrarse en un punto focal (como ocurre en aciertos con parásitos bien definidos), la atención queda difusa sobre toda la célula — consistente con una tinción muy tenue y densidad parasitaria baja.



Fortalezas

Transfer learning en 2 fases, bien implementado

No es solo feature-extraction: el fine-tuning selectivo de los últimos bloques produjo una mejora medible y visible en las curvas (94.9% → 96.6% val accuracy).

Interpretabilidad real, no solo conceptual

Grad-CAM se aplicó sobre una predicción real del modelo, incluyendo un caso de error, en vez de solo describir la técnica de forma teórica.

Métrica clínicamente relevante priorizada

Se reporta y discute el Recall (96.28%) explícitamente, no solo accuracy, reconociendo el costo asimétrico de los falsos negativos en diagnóstico médico.

Entrenamiento eficiente

Precisión mixta (AMP) + batch grande permitieron entrenar 50 épocas sobre 19,290 imágenes en 35.7 minutos en una sola GPU T4.

Limitaciones

Sin etapa de segmentación previa

El modelo clasifica células ya recortadas manualmente. En una laminilla completa (WSI) aún falta el paso de detectar y recortar cada célula automáticamente.

Dataset de una sola fuente

Todas las imágenes provienen de un mismo laboratorio y protocolo de tinción (NIH). El desempeño en imágenes de otros microscopios o tinciones no está validado (domain shift).

Balance de clases artificial

El dataset está balanceado 50/50; la prevalencia real de infección varía por región, lo que afecta el valor predictivo positivo en despliegue real.

Clasificación binaria, no por estadio

No distingue especie de Plasmodium ni estadio del parásito.

77 falsos negativos en test

2.8% de las células realmente infectadas fueron clasificadas como sanas — clínicamente el error más costoso; Grad-CAM sugiere que casos de tinción tenue son los más difíciles.

CONCLUSIÓN

- MalarIA logra 96.76% de exactitud y 96.28% de recall clasificando células de malaria, con evidencia de interpretabilidad honesta vía Grad-CAM.

PRÓXIMOS PASOS

- Segmentación previa sobre laminillas completas (WSI), en vez de células ya recortadas.
- Clasificación multiclase por especie y estadio del parásito.
- Comparar contra un baseline clásico (features + SVM) y otras arquitecturas (MobileNetV3, ResNet-50).
- Validar con datos de otro centro / protocolo de tinción para medir generalización real.
- Desplegar como herramienta de triage con revisión humana obligatoria (human-in-the-loop), dado el riesgo clínico de los falsos negativos.